	Calme		Gemma		Exaone		Granite	
	F_1 es	F_1 en	F_1 es	F_1 en	F_1 es	F_1 en	F_1 es	F_1 en
Title	0.6345	0.5834	0.6125	0.5647	0.5519	0.4990	0.3336	0.3675
CI	(0.61, 0.65)	(0.56, 0.60)	(0.59, 0.63)	(0.54, 0.58)	(0.52, 0.57)	(0.47, 0.52)	(0.30, 0.35)	(0.34, 0.39)
majority	0.6395	0.5869	0.6141	0.5675	0.5624	0.5152	0.3517	0.3773
inclusion	0.6154	0.5676	0.6082	0.5581	0.5242	0.4706	0.3467	0.3811
OrigDesc	0.6387	0.6135	0.6242	0.5932	0.5725	0.5348	0.3352	0.3526
CI	(0.61, 0.66)	(0.59, 0.63)	(0.60, 0.64)	(0.57, 0.61)	(0.54, 0.59)	(0.51, 0.55)	(0.31, 0.35)	(0.32, 0.37)
majority	0.6396	0.6150	0.6266	0.5937	0.5895	0.5496	0.3351	0.3590
inclusion	0.6216	0.5934	0.6251	0.5855	0.5488	0.5056	0.3557	0.3683
Self_Gen_Title	0.6210	0.5714	0.5762	0.5313	0.5062	0.4837	0.2861	0.2984
CI	(0.59, 0.64)	(0.54, 0.59)	(0.55, 0.59)	(0.51, 0.55)	(0.48, 0.53)	(0.46, 0.50)	(0.26, 0.30)	(0.27, 0.32)
majority	0.6249	0.5754	0.5771	0.5330	0.5374	0.5019	0.2761	0.2925
inclusion	0.5991	0.5561	0.5660	0.5213	0.4759	0.4587	0.3196	0.3352
Self_Gen_ Title_Desc	0.6318	0.6182	0.5864	0.5699	0.5463	0.5120	0.2889	0.3295
CI	(0.60, 0.65)	(0.59, 0.64)	(0.56, 0.60)	(0.54, 0.59)	(0.52, 0.56)	(0.48, 0.53)	(0.26, 0.31)	(0.30, 0.35)
majority	0.6339	0.6203	0.5875	0.5721	0.5746	0.5367	0.2799	0.3386
inclusion	0.6191	0.6098	0.5760	0.5594	0.5057	0.4771	0.3271	0.3493
Self_Gen_ Title_Desc_Guide	0.6324	0.6062	0.5351	0.4778	0.4574	0.4275	0.2454	0.2827
CI	(0.60, 0.65)	(0.58, 0.62)	(0.51, 0.55)	(0.58, 0.62)	(0.43, 0.48)	(0.40, 0.45)	(0.22, 0.27)	(0.26, 0.30)
majority	0.6322	0.6084	0.5341	0.4757	0.5002	0.4554	0.2175	0.2760
inclusion	0.6237	0.5939	0.5292	0.4839	0.4208	0.4067	0.3046	0.3228
GPT_Gen_Title	0.6085	0.5657	0.5839	0.5237	0.5249	0.4907	0.2673	0.2979
CI	(0.58, 0.63)	(0.54, 0.58)	(0.56, 0.60)	(0.50, 0.54)	(0.50, 0.54)	(0.47, 0.51)	(0.24, 0.29)	(0.27, 0.32)
majority	0.6111	0.5729	0.5827	0.5242	0.5585	0.5177	0.2569	0.2872
inclusion	0.5928	0.5462	0.5758	0.5162	0.4844	0.4629	0.3218	0.3327
GPT_Gen_ Title_Desc	0.6403	0.6135	0.6138	0.5787	0.5458	0.5243	0.2848	0.3008
CI	(0.61, 0.66)	(0.59, 0.63)	(0.59, 0.63)	(0.55, 0.59)	(0.52, 0.56)	(0.50, 0.54)	(0.26, 0.30)	(0.27, 0.32)
majority	0.6415	0.6169	0.6138	0.5783	0.5665	0.5531	0.2895	0.2972
inclusion	0.6310	0.6006	0.6034	0.5693	0.5047	0.4734	0.3214	0.3379
GPT_Gen_ Title_Desc_Guide	0.6266	0.6048	0.2747	0.3802	0.4846	0.4378	0.2206	0.2717
CI	(0.60, 0.65)	(0.58, 0.62)	(0.24, 0.31)	(0.34, 0.41)	(0.46, 0.50)	(0.41, 0.46)	(0.19, 0.24)	(0.24, 0.29)
majority	0.6370	0.6134	0.2756	0.3852	0.5257	0.4614	0.2055	0.2623
inclusion	0.6117	0.5931	0.3085	0.3926	0.4487	0.4258	0.2761	0.3239

Table A.1: Dipromats results: macro F_1 scores and 95% confidence intervals (CI) by model, prompting strategy, and language.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.3646	0.1638	0.2752	0.0455	0.2879	0.0515	0.0809	0.0129
CI	(0.33, 0.40)	(0.14, 0.19)	(0.24, 0.31)	(0.03, 0.06)	(0.25, 0.32)	(0.04, 0.07)	(0.06, 0.10)	(0.01, 0.02)
majority	0.3765	0.1666	0.2668	0.0408	0.3527	0.0553	0.2009	0.0137
inclusion	0.3851	0.1758	0.2834	0.0607	0.3180	0.0632	0.1281	0.0218
OrigDesc	0.3678	0.1598	0.3794	0.0284	0.2322	0.0436	0.1169	0.0129
CI	(0.33, 0.40)	(0.13, 0.18)	(0.34, 0.42)	(0.01, 0.04)	(0.20, 0.27)	(0.03, 0.06)	(0.09, 0.14)	(0.01, 0.02)
majority	0.4029	0.1625	0.3869	0.0265	0.3048	0.0350	0.2331	0.0207
inclusion	0.4086	0.1805	0.3813	0.0331	0.2603	0.0631	0.1727	0.0215
Self_Gen_Title	×	×	0.2749	0.0376	0.1215	0.0168	0.0882	0.0106
CI	×	×	(0.24, 0.31)	(0.02, 0.05)	(0.10, 0.14)	(0.01, 0.03)	(0.07, 0.11)	(0.01, 0.02)
majority	×	×	0.2618	0.0316	0.1230	0.0136	0.2556	0.0163
inclusion	×	×	0.3033	0.0586	0.1668	0.0264	0.1308	0.0200
Self_Gen_ Title_Desc	×	×	0.3775	0.0267	0.1413	0.0227	0.0785	0.0118
CI	×	×	(0.34, 0.42)	(0.01, 0.04)	(0.12, 0.17)	(0.01, 0.03)	(0.06, 0.10)	(0.01, 0.02)
majority	×	×	0.3791	0.0242	0.1689	0.0136	0.1955	0.0097
inclusion	×	×	0.3810	0.0304	0.1852	0.0358	0.1234	0.0222
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.0598	0.0117
CI	×	×	×	×	×	×	(0.04, 0.08)	(0.01, 0.02)
majority	×	×	×	×	×	×	0.1936	0.0191
inclusion	×	×	×	×	×	×	0.0884	0.0225
GPT_Gen_Title	×	×	0.3680	0.0253	0.1111	0.0178	0.0820	0.0113
CI	×	×	(0.33, 0.41)	(0.01, 0.04)	(0.09, 0.13)	(0.01, 0.03)	(0.06, 0.10)	(0.01, 0.02)
majority	×	×	0.3786	0.0235	0.1265	0.0112	0.2708	0.0152
inclusion	×	×	0.3658	0.0295	0.1681	0.0340	0.1293	0.0240
GPT_Gen_ Title_Desc	×	×	0.3561	0.0320	0.1358	0.0209	0.0724	0.0114
CI	×	×	(0.31, 0.40)	(0.02, 0.05)	(0.11, 0.16)	(0.01, 0.03)	(0.05, 0.09)	(0.01, 0.02)
majority	×	×	0.3677	0.0310	0.1601	0.0149	0.2336	0.0077
inclusion	×	×	0.3654	0.0428	0.1896	0.0332	0.1259	0.0237
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.0671	0.0125
CI	×	×	×	×	×	×	(0.05, 0.08)	(0.01, 0.02)
majority	×	×	×	×	×	×	0.2946	0.0191
inclusion	×	×	×	×	×	×	0.1087	0.0237

Table A.2: SemEval — All-in-One classification results on the EN train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.3392	0.1572	0.2207	0.0368	0.2372	0.0539	0.0837	0.0124
CI	(0.30, 0.38)	(0.13, 0.19)	(0.19, 0.25)	(0.03, 0.05)	(0.21, 0.27)	(0.04, 0.07)	(0.06, 0.11)	(0.01, 0.02)
majority	0.3450	0.1570	0.2201	0.0360	0.2731	0.0479	0.1275	0.0052
inclusion	0.3526	0.1635	0.2355	0.0517	0.2598	0.0646	0.1460	0.0269
OrigDesc	0.3269	0.1448	0.2406	0.0168	0.2003	0.0458	0.1177	0.0126
CI	(0.29, 0.37)	(0.12, 0.17)	(0.20, 0.28)	(0.01, 0.03)	(0.17, 0.23)	(0.03, 0.06)	(0.09, 0.14)	(0.01, 0.02)
majority	0.3333	0.1453	0.2424	0.0099	0.1970	0.0445	0.1669	0.0073
inclusion	0.3601	0.1592	0.2589	0.0334	0.2318	0.0597	0.1770	0.0224
Self_Gen_Title	×	×	0.2396	0.0161	0.1533	0.0407	0.0965	0.0122
CI	×	×	(0.20, 0.28)	(0.01, 0.03)	(0.13, 0.18)	(0.03, 0.06)	(0.08, 0.12)	(0.01, 0.02)
majority	×	×	0.2549	0.0178	0.1384	0.0384	0.1910	0.0035
inclusion	×	×	0.2423	0.0258	0.1971	0.0526	0.1542	0.0257
Self_Gen_ Title_Desc	×	×	0.2463	0.0089	0.1609	0.0453	0.0855	0.0127
CI	×	×	(0.20, 0.29)	(0.00, 0.02)	(0.13, 0.19)	(0.03, 0.06)	(0.06, 0.11)	(0.01, 0.02)
majority	×	×	0.2469	0.0050	0.1566	0.0379	0.1305	0.0049
inclusion	×	×	0.2525	0.0186	0.2086	0.0557	0.1243	0.0226
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.0765	0.0227
CI	×	×	×	×	×	×	(0.06, 0.10)	(0.01, 0.03)
majority	×	×	×	×	×	×	0.1673	0.0222
inclusion	×	×	×	×	×	×	0.1091	0.0310
GPT_Gen_Title	×	×	0.2570	0.0111	0.1559	0.0442	0.0881	0.0170
CI	×	×	(0.22, 0.30)	(0.00, 0.02)	(0.13, 0.19)	(0.03, 0.06)	(0.07, 0.11)	(0.01, 0.03)
majority	×	×	0.2563	0.0087	0.1446	0.0402	0.1743	0.0080
inclusion	×	×	0.2695	0.0198	0.1957	0.0562	0.1427	0.0292
GPT_Gen_ Title_Desc	×	×	0.2511	0.0167	0.1510	0.0448	0.0833	0.0107
CI	×	×	(0.21, 0.29)	(0.01, 0.03)	(0.12, 0.18)	(0.03, 0.06)	(0.06, 0.10)	(0.00, 0.02)
majority	×	×	0.2516	0.0124	0.1336	0.0401	0.1742	0.0058
inclusion	×	×	0.2578	0.0293	0.1931	0.0574	0.1365	0.0242
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.0786	0.0163
CI	×	×	×	×	×	×	(0.06, 0.10)	(0.01, 0.03)
majority	×	×	×	×	×	×	0.1950	0.0145
inclusion	×	×	×	×	×	×	0.1239	0.0279

Table A.3: SemEval — All-in-One classification results on the HI train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.4265	0.2172	0.1918	0.0640	0.2571	0.0675	0.1324	0.0206
CI	(0.39, 0.46)	(0.19, 0.25)	(0.16, 0.22)	(0.05, 0.08)	(0.23, 0.29)	(0.05, 0.08)	(0.11, 0.15)	(0.01, 0.03)
majority	0.4252	0.2209	0.1929	0.0685	0.1796	0.0506	0.1056	0.0068
inclusion	0.4657	0.2272	0.2276	0.0840	0.3219	0.0869	0.1870	0.0374
OrigDesc	0.3905	0.1947	0.0959	0.0146	0.2322	0.0560	0.1392	0.0199
CI	(0.35, 0.43)	(0.17, 0.22)	(0.07, 0.12)	(0.01, 0.02)	(0.21, 0.26)	(0.04, 0.07)	(0.12, 0.16)	(0.01, 0.03)
majority	0.3748	0.1974	0.0730	0.0086	0.1680	0.0491	0.0819	0.0095
inclusion	0.4474	0.2093	0.1512	0.0337	0.3084	0.0767	0.2016	0.0341
Self_Gen_Title	×	×	0.0942	0.0124	0.1887	0.0414	0.1260	0.0207
CI	×	×	(0.07, 0.12)	(0.01, 0.02)	(0.16, 0.21)	(0.03, 0.05)	(0.10, 0.15)	(0.01, 0.03)
majority	×	×	0.0768	0.0036	0.1467	0.0307	0.0925	0.0032
inclusion	×	×	0.1544	0.0332	0.2461	0.0552	0.1664	0.0380
Self_Gen_ Title_Desc	×	×	0.0761	0.0073	0.1895	0.0424	0.1296	0.0214
CI	×	×	(0.05, 0.10)	(0.00, 0.01)	(0.16, 0.21)	(0.03, 0.05)	(0.11, 0.15)	(0.01, 0.03)
majority	×	×	0.0701	0.0041	0.1454	0.0421	0.0909	0.0128
inclusion	×	×	0.0965	0.0152	0.2616	0.0509	0.1721	0.0389
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.0943	0.0259
CI	×	×	×	×	×	×	(0.08, 0.11)	(0.02, 0.04)
majority	×	×	×	×	×	×	0.0722	0.0245
inclusion	×	×	×	×	×	×	0.1501	0.0388
GPT_Gen_Title	×	×	0.0715	0.0039	0.1873	0.0386	0.1265	0.0251
CI	×	×	(0.05, 0.09)	(0.00, 0.01)	(0.16, 0.21)	(0.03, 0.05)	(0.10, 0.15)	(0.02, 0.03)
majority	×	×	0.0670	0.0023	0.1359	0.0335	0.1075	0.0124
inclusion	×	×	0.0798	0.0076	0.2539	0.0526	0.1705	0.0465
GPT_Gen_ Title_Desc	×	×	0.0870	0.0087	0.1725	0.0371	0.1259	0.0203
CI	×	×	(0.06, 0.11)	(0.00, 0.02)	(0.15, 0.20)	(0.03, 0.05)	(0.10, 0.15)	(0.01, 0.03)
majority	×	×	0.0798	0.0048	0.1380	0.0359	0.0892	0.0054
inclusion	×	×	0.1232	0.0207	0.2395	0.0482	0.1848	0.0400
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.1189	0.0223
CI	×	×	×	×	×	×	(0.10, 0.14)	(0.01, 0.03)
majority	×	×	×	×	×	×	0.0788	0.0104
inclusion	×	×	×	×	×	×	0.1854	0.0412

Table A.4: SemEval — All-in-One classification results on the PT train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.4969	0.2773	0.1728	0.0733	0.2883	0.0913	0.1602	0.0296
CI	(0.46, 0.53)	(0.25, 0.31)	(0.14, 0.20)	(0.06, 0.09)	(0.26, 0.31)	(0.07, 0.11)	(0.14, 0.18)	(0.02, 0.04)
majority	0.5056	0.2933	0.1622	0.0729	0.2311	0.0774	0.1356	0.0161
inclusion	0.5065	0.2678	0.2133	0.1020	0.3199	0.1123	0.1999	0.0521
OrigDesc	0.5162	0.3034	0.1161	0.0278	0.2603	0.0736	0.1435	0.0188
CI	(0.48, 0.55)	(0.27, 0.34)	(0.09, 0.15)	(0.02, 0.04)	(0.23, 0.29)	(0.06, 0.09)	(0.12, 0.17)	(0.01, 0.03)
majority	0.5154	0.3085	0.0985	0.0198	0.1939	0.0482	0.1185	0.0054
inclusion	0.5417	0.3049	0.1749	0.0564	0.2948	0.1047	0.1778	0.0341
Self_Gen_Title	×	×	0.1240	0.0317	0.1953	0.0347	0.1441	0.0199
CI	×	×	(0.10, 0.15)	(0.02, 0.05)	(0.17, 0.22)	(0.02, 0.05)	(0.12, 0.17)	(0.01, 0.03)
majority	×	×	0.1063	0.0262	0.1576	0.0229	0.1368	0.0160
inclusion	×	×	0.1775	0.0591	0.2309	0.0535	0.1729	0.0324
Self_Gen_ Title_Desc	×	×	0.0974	0.0188	0.2016	0.0503	0.1598	0.0188
CI	×	×	(0.07, 0.12)	(0.01, 0.03)	(0.18, 0.23)	(0.04, 0.06)	(0.13, 0.19)	(0.01, 0.03)
majority	×	×	0.0881	0.0138	0.1735	0.0433	0.1463	0.0120
inclusion	×	×	0.1236	0.0303	0.2408	0.0709	0.1757	0.0345
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.1121	0.0209
CI	×	×	×	×	×	×	(0.09, 0.13)	(0.01, 0.03)
majority	×	×	×	×	×	×	0.0786	0.0167
inclusion	×	×	×	×	×	×	0.1556	0.0351
GPT_Gen_Title	×	×	0.0889	0.0166	0.1965	0.0349	0.1437	0.0220
CI	×	×	(0.06, 0.12)	(0.01, 0.03)	(0.17, 0.22)	(0.02, 0.05)	(0.12, 0.17)	(0.01, 0.03)
majority	×	×	0.0826	0.0138	0.1658	0.0274	0.1245	0.0197
inclusion	×	×	0.1063	0.0251	0.2381	0.0566	0.1619	0.0396
GPT_Gen_ Title_Desc	×	×	0.1094	0.0274	0.1940	0.0371	0.1469	0.0202
CI	×	×	(0.08, 0.14)	(0.01, 0.04)	(0.17, 0.22)	(0.02, 0.05)	(0.12, 0.17)	(0.01, 0.03)
majority	×	×	0.0963	0.0209	0.1615	0.0283	0.1320	0.0159
inclusion	×	×	0.1455	0.0484	0.2389	0.0557	0.1694	0.0356
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.1258	0.0212
CI	×	×	×	×	×	×	(0.10, 0.15)	(0.01, 0.03)
majority	×	×	×	×	×	×	0.0898	0.0174
inclusion	×	×	×	×	×	×	0.1677	0.0360

Table A.5: SemEval — All-in-One classification results on the BG train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.5376	0.3248	0.1077	0.0491	0.3001	0.0930	0.2322	0.0397
CI	(0.49, 0.58)	(0.28, 0.37)	(0.08, 0.14)	(0.03, 0.07)	(0.26, 0.34)	(0.07, 0.12)	(0.20, 0.27)	(0.03, 0.06)
majority	0.5297	0.3310	0.1198	0.0537	0.2159	0.0852	0.1472	0.0231
inclusion	0.5587	0.3222	0.1302	0.0618	0.3194	0.1093	0.2748	0.0716
OrigDesc	0.5099	0.3110	0.0532	0.0264	0.2608	0.0606	0.2304	0.0235
CI	(0.46, 0.56)	(0.27, 0.35)	(0.03, 0.08)	(0.01, 0.04)	(0.23, 0.30)	(0.04, 0.08)	(0.19, 0.27)	(0.01, 0.04)
majority	0.5032	0.3095	0.0398	0.0202	0.1295	0.0375	0.1512	0.0196
inclusion	0.5393	0.3243	0.0944	0.0485	0.3183	0.0893	0.2607	0.0457
Self_Gen_Title	×	×	0.0618	0.0293	0.2869	0.0407	0.2555	0.0400
CI	×	×	(0.04, 0.09)	(0.01, 0.05)	(0.25, 0.32)	(0.02, 0.06)	(0.22, 0.29)	(0.02, 0.06)
majority	×	×	0.0435	0.0232	0.2567	0.0328	0.1964	0.0142
inclusion	×	×	0.1189	0.0561	0.3020	0.0624	0.2577	0.0734
Self_Gen_ Title_Desc	×	×	0.0433	0.0214	0.2733	0.0518	0.2820	0.0202
CI	×	×	(0.02, 0.07)	(0.01, 0.04)	(0.24, 0.31)	(0.03, 0.07)	(0.24, 0.33)	(0.01, 0.03)
majority	×	×	0.0324	0.0162	0.2121	0.0437	0.2327	0.0192
inclusion	×	×	0.0669	0.0343	0.3112	0.0707	0.2920	0.0396
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.1712	0.0357
CI	×	×	×	×	×	×	(0.14, 0.21)	(0.02, 0.05)
majority	×	×	×	×	×	×	0.0850	0.0354
inclusion	×	×	×	×	×	×	0.2558	0.0633
GPT_Gen_Title	×	×	0.0376	0.0185	0.2816	0.0362	0.2648	0.0562
CI	×	×	(0.02, 0.06)	(0.00, 0.03)	(0.25, 0.32)	(0.02, 0.05)	(0.22, 0.31)	(0.04, 0.08)
majority	×	×	0.0324	0.0162	0.2651	0.0258	0.1489	0.0377
inclusion	×	×	0.0536	0.0262	0.2942	0.0634	0.2823	0.0878
GPT_Gen_ Title_Desc	×	×	0.0472	0.0214	0.2738	0.0399	0.2567	0.0446
CI	×	×	(0.03, 0.07)	(0.01, 0.04)	(0.24, 0.31)	(0.02, 0.06)	(0.21, 0.30)	(0.03, 0.06)
majority	×	×	0.0412	0.0212	0.2405	0.0279	0.1190	0.0275
inclusion	×	×	0.0830	0.0330	0.3228	0.0644	0.2884	0.0771
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.2284	0.0309
CI	×	×	×	×	×	×	(0.19, 0.27)	(0.02, 0.05)
majority	×	×	×	×	×	×	0.1209	0.0111
inclusion	×	×	×	×	×	×	0.3117	0.0620

Table A.6: SemEval — All-in-One classification results on the RU train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.4179	0.1739	0.3560	0.1690	0.3325	0.1100	0.2882	0.0474
CI	(0.38, 0.46)	(0.15, 0.20)	(0.32, 0.39)	(0.15, 0.19)	(0.29, 0.37)	(0.09, 0.13)	(0.25, 0.33)	(0.03, 0.06)
majority	0.4404	0.1831	0.3599	0.1736	0.3358	0.1068	0.3417	0.0468
inclusion	0.4399	0.1793	0.3748	0.1670	0.3688	0.1243	0.3021	0.0632
OrigDesc	0.4591	0.1884	0.3774	0.1789	0.3326	0.1049	0.2859	0.0466
CI	(0.42, 0.50)	(0.16, 0.22)	(0.34, 0.41)	(0.16, 0.20)	(0.30, 0.37)	(0.09, 0.13)	(0.25, 0.32)	(0.03, 0.06)
majority	0.4664	0.1928	0.3795	0.1912	0.3416	0.1015	0.3303	0.0383
inclusion	0.4794	0.1993	0.4072	0.1805	0.3578	0.1195	0.2961	0.0625
Self_Gen_Title	0.4050	0.1498	0.3338	0.1029	0.2353	0.0806	0.1871	0.0381
CI	(0.37, 0.44)	(0.13, 0.17)	(0.29, 0.37)	(0.08, 0.12)	(0.20, 0.27)	(0.06, 0.10)	(0.16, 0.22)	(0.03, 0.05)
majority	0.4196	0.1544	0.3383	0.1107	0.2685	0.0830	0.2877	0.0355
inclusion	0.4338	0.1637	0.3911	0.1340	0.2691	0.0909	0.2286	0.0502
Self_Gen_ Title_Desc	0.4363	0.1614	0.3325	0.1372	0.2969	0.0979	0.1869	0.0325
CI	(0.40, 0.47)	(0.14, 0.19)	(0.30, 0.37)	(0.12, 0.16)	(0.26, 0.33)	(0.08, 0.12)	(0.15, 0.22)	(0.02, 0.04)
majority	0.4518	0.1690	0.3578	0.1432	0.3397	0.1044	0.2720	0.0274
inclusion	0.4647	0.1673	0.3924	0.1592	0.3387	0.1145	0.2169	0.0469
Self_Gen_ Title_Desc_Guide	0.4258	0.1558	0.4092	0.0252	0.2153	0.0792	0.1529	0.0332
CI	(0.39, 0.46)	(0.13, 0.18)	(0.37, 0.46)	(0.01, 0.04)	(0.19, 0.25)	(0.06, 0.10)	(0.13, 0.18)	(0.02, 0.04)
majority	0.4403	0.1604	0.4091	0.0250	0.3316	0.0822	0.2512	0.0360
inclusion	0.4609	0.1664	0.4091	0.0250	0.2755	0.1018	0.1945	0.0440
GPT_Gen_Title	0.3871	0.1398	0.2993	0.1263	0.2530	0.0816	0.1612	0.0331
CI	(0.35, 0.42)	(0.12, 0.16)	(0.27, 0.33)	(0.11, 0.15)	(0.22, 0.29)	(0.07, 0.10)	(0.13, 0.19)	(0.02, 0.05)
majority	0.3958	0.1408	0.2978	0.1344	0.2814	0.0801	0.2794	0.0237
inclusion	0.4228	0.1571	0.3371	0.1369	0.2900	0.0987	0.2046	0.0516
GPT_Gen_ Title_Desc	0.4656	0.1685	0.3145	0.1257	0.3059	0.1064	0.1831	0.0368
CI	(0.43, 0.50)	(0.14, 0.20)	(0.28, 0.35)	(0.11, 0.15)	(0.27, 0.34)	(0.09, 0.13)	(0.15, 0.21)	(0.02, 0.05)
majority	0.4780	0.1702	0.3414	0.1368	0.3534	0.1176	0.2543	0.0270
inclusion	0.5000	0.1870	0.3586	0.1482	0.3306	0.1154	0.2182	0.0506
GPT_Gen_ Title_Desc_Guide	0.4289	0.1567	0.3414	0.0574	0.2425	0.0859	0.1469	0.0353
CI	(0.39, 0.47)	(0.13, 0.18)	(0.30, 0.38)	(0.04, 0.07)	(0.21, 0.28)	(0.07, 0.10)	(0.12, 0.17)	(0.02, 0.05)
majority	0.4421	0.1609	0.3398	0.0571	0.2732	0.0879	0.2508	0.0304
inclusion	0.4616	0.1730	0.3665	0.0684	0.2854	0.0980	0.1838	0.0521

Table A.7: SemEval — Three-Step classification results on the EN train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.3359	0.1490	0.3118	0.1722	0.3211	0.1099	0.2127	0.0510
CI	(0.30, 0.38)	(0.12, 0.18)	(0.28, 0.35)	(0.15, 0.20)	(0.28, 0.36)	(0.09, 0.14)	(0.18, 0.24)	(0.04, 0.06)
majority	0.3293	0.1488	0.3157	0.1770	0.3290	0.1154	0.2309	0.0352
inclusion	0.3669	0.1595	0.3145	0.1651	0.3508	0.1197	0.2397	0.0664
OrigDesc	0.3880	0.1507	0.3277	0.1731	0.3472	0.1124	0.2436	0.0580
CI	(0.35, 0.43)	(0.12, 0.18)	(0.29, 0.36)	(0.15, 0.20)	(0.31, 0.39)	(0.09, 0.14)	(0.21, 0.28)	(0.04, 0.07)
majority	0.3816	0.1546	0.3307	0.1765	0.3586	0.1242	0.2723	0.0588
inclusion	0.4179	0.1578	0.3261	0.1723	0.3779	0.1213	0.2609	0.0646
Self_Gen_Title	0.3817	0.1387	0.2592	0.0849	0.2743	0.0864	0.1644	0.0527
CI	(0.34, 0.42)	(0.11, 0.17)	(0.22, 0.30)	(0.07, 0.11)	(0.24, 0.31)	(0.07, 0.11)	(0.14, 0.19)	(0.04, 0.07)
majority	0.3760	0.1434	0.2719	0.0946	0.2733	0.0846	0.1889	0.0410
inclusion	0.4114	0.1492	0.3149	0.1241	0.3043	0.0990	0.2242	0.0729
Self_Gen_ Title_Desc	0.3846	0.1388	0.2606	0.1118	0.3104	0.1065	0.1739	0.0620
CI	(0.34, 0.43)	(0.11, 0.17)	(0.23, 0.30)	(0.09, 0.13)	(0.27, 0.35)	(0.08, 0.13)	(0.15, 0.20)	(0.05, 0.08)
majority	0.3834	0.1418	0.2777	0.1342	0.3360	0.1119	0.2327	0.0550
inclusion	0.4064	0.1442	0.3056	0.1347	0.3281	0.1143	0.2209	0.0724
Self_Gen_ Title_Desc_Guide	0.3852	0.1290	0.2496	0.0049	0.2192	0.0594	0.1803	0.0671
CI	(0.34, 0.43)	(0.10, 0.16)	(0.21, 0.29)	(0.00, 0.01)	(0.19, 0.25)	(0.04, 0.08)	(0.15, 0.21)	(0.05, 0.08)
majority	0.3758	0.1271	0.2494	0.0050	0.2477	0.0463	0.2305	0.0492
inclusion	0.4192	0.1439	0.2494	0.0050	0.2812	0.0769	0.2267	0.0834
GPT_Gen_Title	0.3250	0.1107	0.2620	0.1018	0.2780	0.0824	0.1622	0.0521
CI	(0.29, 0.37)	(0.09, 0.13)	(0.23, 0.30)	(0.08, 0.12)	(0.24, 0.32)	(0.06, 0.10)	(0.14, 0.19)	(0.04, 0.07)
majority	0.3278	0.1103	0.2693	0.1144	0.2891	0.0812	0.2253	0.0357
inclusion	0.3602	0.1265	0.2985	0.1208	0.3137	0.0952	0.2101	0.0680
GPT_Gen_ Title_Desc	0.3652	0.1199	0.2793	0.1162	0.3040	0.1001	0.1646	0.0524
CI	(0.32, 0.41)	(0.09, 0.15)	(0.24, 0.32)	(0.10, 0.14)	(0.27, 0.34)	(0.08, 0.12)	(0.14, 0.19)	(0.04, 0.07)
majority	0.3632	0.1180	0.2990	0.1327	0.3341	0.1131	0.2152	0.0329
inclusion	0.3957	0.1314	0.3219	0.1429	0.3350	0.1071	0.2078	0.0666
GPT_Gen_ Title_Desc_Guide	0.3679	0.1226	0.2680	0.0999	0.2998	0.1162	0.1480	0.0526
CI	(0.33, 0.41)	(0.10, 0.15)	(0.23, 0.30)	(0.08, 0.12)	(0.26, 0.34)	(0.09, 0.14)	(0.12, 0.18)	(0.04, 0.07)
majority	0.3643	0.1210	0.2685	0.1035	0.3091	0.1263	0.2304	0.0365
inclusion	0.3888	0.1364	0.3197	0.1332	0.3342	0.1204	0.1956	0.0687

Table A.8: SemEval — Three-Step classification results on the HI train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.5165	0.2737	0.5812	0.2561	0.4436	0.2029	0.2068	0.0742
CI	(0.48, 0.55)	(0.24, 0.31)	(0.55, 0.61)	(0.23, 0.28)	(0.41, 0.48)	(0.17, 0.23)	(0.18, 0.23)	(0.06, 0.09)
majority	0.5163	0.2742	0.5071	0.2187	0.4445	0.2074	0.1723	0.0715
inclusion	0.5432	0.2788	0.5032	0.2046	0.4672	0.2057	0.2743	0.0943
OrigDesc	0.5407	0.2786	0.5535	0.2601	0.4415	0.1825	0.2295	0.0659
CI	(0.50, 0.58)	(0.25, 0.31)	(0.51, 0.60)	(0.22, 0.30)	(0.41, 0.48)	(0.15, 0.21)	(0.20, 0.25)	(0.05, 0.08)
majority	0.5314	0.2762	0.1151	0.0268	0.4432	0.1892	0.1919	0.0615
inclusion	0.5809	0.2925	0.1382	0.0369	0.4682	0.1876	0.2925	0.0882
Self_Gen_Title	0.4738	0.2297	0.3402	0.1349	0.4173	0.1744	0.1937	0.0556
CI	(0.44, 0.51)	(0.20, 0.26)	(0.29, 0.39)	(0.11, 0.17)	(0.38, 0.45)	(0.15, 0.20)	(0.17, 0.22)	(0.04, 0.07)
majority	0.4579	0.2233	0.0972	0.0144	0.4331	0.1818	0.1424	0.0340
inclusion	0.5304	0.2487	0.1143	0.0217	0.4427	0.1824	0.2828	0.0862
Self_Gen_ Title_Desc	0.4576	0.2105	0.3588	0.1558	0.4132	0.1594	0.2076	0.0557
CI	(0.42, 0.49)	(0.18, 0.24)	(0.33, 0.39)	(0.13, 0.18)	(0.38, 0.45)	(0.14, 0.18)	(0.18, 0.23)	(0.04, 0.07)
majority	0.4457	0.2087	0.4121	0.1789	0.4184	0.1665	0.1467	0.0349
inclusion	0.5112	0.2263	0.4191	0.1836	0.4377	0.1728	0.2889	0.0850
Self_Gen_ Title_Desc_Guide	0.4665	0.2111	0.0649	0.0027	0.3322	0.1283	0.2052	0.0557
CI	(0.43, 0.50)	(0.18, 0.24)	(0.04, 0.09)	(0.00, 0.01)	(0.30, 0.36)	(0.11, 0.15)	(0.18, 0.23)	(0.04, 0.07)
majority	0.4478	0.2084	0.0644	0.0023	0.3010	0.1181	0.1433	0.0369
inclusion	0.5093	0.2268	0.0662	0.0038	0.4083	0.1550	0.2825	0.0791
GPT_Gen_Title	0.4539	0.2153	0.3703	0.1489	0.3858	0.1569	0.2104	0.0543
CI	(0.42, 0.49)	(0.19, 0.24)	(0.34, 0.40)	(0.13, 0.17)	(0.35, 0.42)	(0.13, 0.18)	(0.19, 0.24)	(0.04, 0.07)
majority	0.4596	0.2228	0.4261	0.1698	0.4008	0.1699	0.1668	0.0270
inclusion	0.4904	0.2259	0.4203	0.1697	0.4027	0.1541	0.2912	0.0863
GPT_Gen_ Title_Desc	0.4548	0.2195	0.3749	0.1652	0.3943	0.1586	0.1780	0.0493
CI	(0.42, 0.49)	(0.19, 0.25)	(0.34, 0.41)	(0.14, 0.19)	(0.36, 0.43)	(0.13, 0.18)	(0.16, 0.20)	(0.04, 0.06)
majority	0.4398	0.2230	0.4240	0.1919	0.4205	0.1717	0.1229	0.0356
inclusion	0.5092	0.2303	0.4287	0.1907	0.4067	0.1563	0.2636	0.0694
GPT_Gen_ Title_Desc_Guide	0.4695	0.2179	0.3259	0.1080	0.4003	0.1651	0.1888	0.0477
CI	(0.43, 0.50)	(0.19, 0.25)	(0.28, 0.37)	(0.09, 0.13)	(0.37, 0.43)	(0.14, 0.19)	(0.16, 0.22)	(0.03, 0.06)
majority	0.4545	0.2119	0.0931	0.0103	0.4103	0.1705	0.1252	0.0358
inclusion	0.5146	0.2343	0.1126	0.0193	0.4214	0.1674	0.2784	0.0686

Table A.9: SemEval — Three-Step classification results on the PT train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.4865	0.3095	0.4687	0.2585	0.4204	0.2507	0.1766	0.0710
CI	(0.45, 0.52)	(0.28, 0.34)	(0.44, 0.50)	(0.24, 0.28)	(0.39, 0.45)	(0.22, 0.28)	(0.15, 0.20)	(0.06, 0.09)
majority	0.4859	0.3051	0.3070	0.1586	0.4242	0.2632	0.1414	0.0584
inclusion	0.4821	0.3096	0.2965	0.1441	0.4126	0.2345	0.2270	0.0935
OrigDesc	0.5184	0.3360	0.4756	0.2812	0.4094	0.2375	0.2083	0.0878
CI	(0.49, 0.55)	(0.30, 0.37)	(0.44, 0.51)	(0.26, 0.30)	(0.38, 0.44)	(0.21, 0.27)	(0.19, 0.23)	(0.07, 0.10)
majority	0.5190	0.3395	0.4920	0.2990	0.4225	0.2501	0.1666	0.0739
inclusion	0.5275	0.3419	0.4742	0.2750	0.4062	0.2242	0.2568	0.1072
Self_Gen_Title	0.4683	0.3093	0.2631	0.1251	0.3561	0.2047	0.1887	0.0711
CI	(0.43, 0.50)	(0.28, 0.34)	(0.23, 0.30)	(0.11, 0.15)	(0.32, 0.39)	(0.18, 0.23)	(0.16, 0.21)	(0.06, 0.09)
majority	0.4753	0.3146	0.2530	0.1277	0.3734	0.2207	0.1518	0.0564
inclusion	0.4797	0.3109	0.3809	0.1982	0.3683	0.2005	0.2576	0.0924
Self_Gen_ Title_Desc	0.4883	0.3297	0.3338	0.1832	0.3878	0.1969	0.1872	0.0708
CI	(0.45, 0.52)	(0.30, 0.36)	(0.30, 0.37)	(0.16, 0.21)	(0.36, 0.42)	(0.17, 0.22)	(0.16, 0.21)	(0.06, 0.09)
majority	0.4953	0.3399	0.3640	0.2038	0.3993	0.2147	0.1323	0.0477
inclusion	0.4986	0.3287	0.4002	0.2286	0.3980	0.1940	0.2525	0.0995
Self_Gen_ Title_Desc_Guide	0.5042	0.3009	0.0825	0.0139	0.3336	0.1533	0.1863	0.0576
CI	(0.47, 0.54)	(0.27, 0.33)	(0.06, 0.11)	(0.00, 0.03)	(0.30, 0.37)	(0.13, 0.18)	(0.16, 0.21)	(0.04, 0.07)
majority	0.5059	0.3100	0.0826	0.0138	0.3325	0.1473	0.1355	0.0429
inclusion	0.5112	0.2985	0.0826	0.0138	0.3558	0.1782	0.2513	0.0806
GPT_Gen_Title	0.4343	0.2766	0.3172	0.1578	0.3474	0.1874	0.2202	0.0668
CI	(0.40, 0.47)	(0.25, 0.31)	(0.28, 0.35)	(0.14, 0.18)	(0.31, 0.38)	(0.16, 0.21)	(0.19, 0.25)	(0.05, 0.08)
majority	0.4360	0.2840	0.3473	0.1699	0.3592	0.1998	0.2050	0.0407
inclusion	0.4492	0.2758	0.3709	0.1930	0.3453	0.1762	0.2625	0.0980
GPT_Gen_ Title_Desc	0.4711	0.2984	0.3244	0.1755	0.4001	0.2202	0.1946	0.0610
CI	(0.44, 0.50)	(0.27, 0.33)	(0.29, 0.36)	(0.15, 0.20)	(0.37, 0.43)	(0.19, 0.25)	(0.17, 0.22)	(0.05, 0.07)
majority	0.4723	0.3053	0.2784	0.1486	0.4328	0.2492	0.1361	0.0426
inclusion	0.4960	0.3065	0.3961	0.2247	0.3827	0.2029	0.2574	0.0871
GPT_Gen_ Title_Desc_Guide	0.4561	0.2800	0.2741	0.1378	0.3654	0.2034	0.1798	0.0503
CI	(0.42, 0.49)	(0.25, 0.31)	(0.24, 0.31)	(0.12, 0.16)	(0.33, 0.40)	(0.18, 0.23)	(0.16, 0.20)	(0.04, 0.07)
majority	0.4557	0.2841	0.2755	0.1428	0.3779	0.2099	0.1198	0.0308
inclusion	0.4610	0.2783	0.3511	0.1896	0.3753	0.2017	0.2438	0.0719

Table A.10: SemEval — Three-Step classification results on the BG train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.4696	0.2977	0.3867	0.2002	0.3221	0.1583	0.2071	0.0879
CI	(0.43, 0.51)	(0.26, 0.34)	(0.36, 0.42)	(0.17, 0.22)	(0.28, 0.36)	(0.13, 0.19)	(0.18, 0.24)	(0.07, 0.11)
majority	0.4676	0.3053	0.4080	0.2159	0.3235	0.1648	0.1545	0.0668
inclusion	0.4745	0.2992	0.3919	0.2000	0.3402	0.1617	0.2750	0.1114
OrigDesc	0.5140	0.3076	0.3813	0.2136	0.2971	0.1187	0.2384	0.0835
CI	(0.47, 0.56)	(0.27, 0.35)	(0.35, 0.42)	(0.19, 0.24)	(0.26, 0.34)	(0.09, 0.15)	(0.20, 0.27)	(0.06, 0.10)
majority	0.5109	0.3082	0.4100	0.2364	0.2820	0.1141	0.1689	0.0742
inclusion	0.5297	0.3150	0.3756	0.2122	0.3262	0.1364	0.3020	0.1047
Self_Gen_Title	0.4431	0.2786	0.1840	0.0765	0.3225	0.1370	0.1596	0.0517
CI	(0.40, 0.49)	(0.24, 0.32)	(0.15, 0.22)	(0.06, 0.10)	(0.28, 0.37)	(0.11, 0.17)	(0.13, 0.19)	(0.04, 0.07)
majority	0.4476	0.2833	0.1719	0.0718	0.3051	0.1416	0.0941	0.0324
inclusion	0.4613	0.2926	0.3031	0.1298	0.3312	0.1581	0.2599	0.0813
Self_Gen_ Title_Desc	0.4757	0.2558	0.2632	0.1296	0.3013	0.1110	0.2369	0.0685
CI	(0.43, 0.52)	(0.22, 0.30)	(0.23, 0.30)	(0.11, 0.15)	(0.26, 0.34)	(0.08, 0.14)	(0.21, 0.27)	(0.05, 0.09)
majority	0.4812	0.2708	0.2828	0.1444	0.3063	0.1053	0.1335	0.0427
inclusion	0.5001	0.2765	0.3234	0.1621	0.3293	0.1400	0.3226	0.1060
Self_Gen_ Title_Desc_Guide	0.4304	0.2463	0.0320	0.0161	0.2887	0.1252	0.1606	0.0596
CI	(0.38, 0.48)	(0.21, 0.29)	(0.01, 0.05)	(0.00, 0.03)	(0.25, 0.33)	(0.09, 0.16)	(0.13, 0.19)	(0.04, 0.08)
majority	0.4397	0.2408	0.0324	0.0162	0.2351	0.1069	0.0964	0.0425
inclusion	0.4459	0.2644	0.0324	0.0162	0.3468	0.1548	0.2510	0.0855
GPT_Gen_Title	0.4132	0.2385	0.2017	0.0984	0.2661	0.0998	0.2469	0.0600
CI	(0.37, 0.46)	(0.20, 0.28)	(0.17, 0.24)	(0.08, 0.12)	(0.23, 0.31)	(0.08, 0.13)	(0.21, 0.28)	(0.04, 0.08)
majority	0.4117	0.2487	0.2326	0.1160	0.2682	0.1079	0.1780	0.0291
inclusion	0.4358	0.2507	0.2761	0.1387	0.2882	0.1159	0.3044	0.0941
GPT_Gen_ Title_Desc	0.4476	0.2606	0.2141	0.1061	0.2839	0.1140	0.2124	0.0623
CI	(0.40, 0.49)	(0.22, 0.30)	(0.18, 0.25)	(0.08, 0.13)	(0.25, 0.32)	(0.09, 0.14)	(0.18, 0.24)	(0.04, 0.08)
majority	0.4456	0.2668	0.2260	0.1164	0.2821	0.1219	0.1359	0.0444
inclusion	0.4644	0.2709	0.2958	0.1562	0.3017	0.1258	0.2818	0.0902
GPT_Gen_ Title_Desc_Guide	0.3879	0.2335	0.1903	0.0881	0.2594	0.1162	0.1927	0.0355
CI	(0.34, 0.43)	(0.20, 0.27)	(0.16, 0.22)	(0.07, 0.11)	(0.22, 0.30)	(0.09, 0.15)	(0.16, 0.22)	(0.02, 0.05)
majority	0.3680	0.2288	0.1857	0.0853	0.2431	0.1217	0.1359	0.0416
inclusion	0.4143	0.2474	0.2611	0.1224	0.2928	0.1301	0.2762	0.0532

Table A.11: SemEval — Three-Step classification results on the RU train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.4199	0.1914	0.3057	0.0582	0.3069	0.0625	0.1572	0.0290
CI	(0.38, 0.46)	(0.17, 0.22)	(0.27, 0.34)	(0.04, 0.07)	(0.27, 0.34)	(0.05, 0.08)	(0.13, 0.18)	(0.02, 0.04)
majority	0.4260	0.1969	0.2940	0.0545	0.3151	0.0632	0.3088	0.0269
inclusion	0.4396	0.1949	0.3280	0.0774	0.3468	0.0742	0.2164	0.0480
OrigDesc	0.4396	0.2011	0.3017	0.0762	0.2935	0.0640	0.1599	0.0246
CI	(0.40, 0.48)	(0.17, 0.23)	(0.27, 0.34)	(0.06, 0.09)	(0.26, 0.32)	(0.05, 0.08)	(0.13, 0.19)	(0.02, 0.03)
majority	0.4569	0.2119	0.2811	0.0708	0.3051	0.0627	0.3245	0.0230
inclusion	0.4591	0.2081	0.3657	0.1076	0.3320	0.0746	0.2321	0.0443
Self_Gen_Title	0.3847	0.1664	0.3140	0.0797	0.2480	0.0488	0.1615	0.0194
CI	(0.35, 0.42)	(0.14, 0.19)	(0.28, 0.35)	(0.06, 0.10)	(0.22, 0.28)	(0.04, 0.06)	(0.13, 0.19)	(0.01, 0.03)
majority	0.4066	0.1678	0.2970	0.0784	0.2663	0.0449	0.2689	0.0184
inclusion	0.4145	0.1743	0.3766	0.1091	0.2982	0.0680	0.2308	0.0366
Self_Gen_ Title_Desc	0.4056	0.1734	0.3029	0.0890	0.3064	0.0483	0.1652	0.0191
CI	(0.37, 0.44)	(0.15, 0.20)	(0.27, 0.34)	(0.07, 0.11)	(0.27, 0.34)	(0.03, 0.06)	(0.14, 0.19)	(0.01, 0.03)
majority	0.4134	0.1846	0.3026	0.0917	0.3674	0.0438	0.2869	0.0214
inclusion	0.4389	0.1792	0.3658	0.1188	0.3509	0.0721	0.2318	0.0356
Self_Gen_ Title_Desc_Guide	0.3973	0.1530	0.3298	0.0437	0.1949	0.0369	0.0959	0.0148
CI	(0.36, 0.43)	(0.13, 0.18)	(0.29, 0.37)	(0.03, 0.06)	(0.17, 0.22)	(0.03, 0.05)	(0.08, 0.12)	(0.01, 0.02)
majority	0.4187	0.1572	0.3311	0.0413	0.3096	0.0394	0.3114	0.0224
inclusion	0.4332	0.1680	0.3919	0.0620	0.2661	0.0533	0.1609	0.0306
GPT_Gen_Title	0.3680	0.1708	0.3426	0.0628	0.2311	0.0502	0.1480	0.0228
CI	(0.33, 0.41)	(0.15, 0.20)	(0.31, 0.38)	(0.05, 0.08)	(0.20, 0.26)	(0.04, 0.06)	(0.12, 0.17)	(0.01, 0.03)
majority	0.3783	0.1790	0.3596	0.0682	0.2621	0.0419	0.2716	0.0286
inclusion	0.3942	0.1794	0.3814	0.0883	0.2700	0.0640	0.2018	0.0358
GPT_Gen_ Title_Desc	0.4097	0.1786	0.3053	0.0717	0.2434	0.0498	0.1530	0.0195
CI	(0.37, 0.45)	(0.15, 0.21)	(0.27, 0.35)	(0.06, 0.09)	(0.21, 0.27)	(0.04, 0.06)	(0.13, 0.18)	(0.01, 0.03)
majority	0.4455	0.1972	0.2870	0.0765	0.2710	0.0453	0.2883	0.0239
inclusion	0.4311	0.1832	0.3651	0.1013	0.3024	0.0702	0.2184	0.0372
GPT_Gen_ Title_Desc_Guide	0.4085	0.1639	0.3223	0.0582	0.2255	0.0394	0.1167	0.0170
CI	(0.37, 0.45)	(0.14, 0.19)	(0.29, 0.36)	(0.04, 0.08)	(0.20, 0.26)	(0.03, 0.05)	(0.09, 0.14)	(0.01, 0.03)
majority	0.4205	0.1673	0.3213	0.0552	0.2650	0.0279	0.2688	0.0161
inclusion	0.4395	0.1748	0.3762	0.0853	0.2714	0.0573	0.1877	0.0332

Table A.12: SemEval — Hybrid classification results on the EN train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.3794	0.1629	0.2183	0.0652	0.2658	0.0694	0.1066	0.0158
CI	(0.34, 0.42)	(0.14, 0.19)	(0.18, 0.25)	(0.05, 0.08)	(0.23, 0.30)	(0.05, 0.09)	(0.08, 0.13)	(0.01, 0.02)
majority	0.3699	0.1770	0.2105	0.0597	0.2743	0.0658	0.1518	0.0037
inclusion	0.4162	0.1638	0.2756	0.0793	0.3019	0.0857	0.1630	0.0323
OrigDesc	0.3877	0.1471	0.2079	0.0606	0.2589	0.0683	0.1070	0.0182
CI	(0.35, 0.43)	(0.12, 0.18)	(0.17, 0.24)	(0.05, 0.08)	(0.23, 0.29)	(0.05, 0.09)	(0.08, 0.13)	(0.01, 0.03)
majority	0.3884	0.1545	0.1942	0.0537	0.2770	0.0710	0.1957	0.0086
inclusion	0.4168	0.1531	0.2472	0.0749	0.2898	0.0766	0.1798	0.0348
Self_Gen_Title	0.3679	0.1622	0.2371	0.0623	0.2171	0.0548	0.1173	0.0099
CI	(0.33, 0.41)	(0.13, 0.19)	(0.20, 0.27)	(0.05, 0.08)	(0.19, 0.25)	(0.04, 0.07)	(0.09, 0.14)	(0.00, 0.02)
majority	0.3653	0.1633	0.2346	0.0592	0.2125	0.0442	0.2002	0.0031
inclusion	0.3857	0.1732	0.2734	0.0829	0.2670	0.0770	0.1832	0.0202
Self_Gen_ Title_Desc	0.3647	0.1440	0.2287	0.0631	0.2223	0.0645	0.0863	0.0084
CI	(0.32, 0.40)	(0.12, 0.17)	(0.20, 0.26)	(0.05, 0.08)	(0.19, 0.25)	(0.05, 0.08)	(0.07, 0.11)	(0.00, 0.01)
majority	0.3492	0.1464	0.2138	0.0627	0.2242	0.0593	0.1907	0.0052
inclusion	0.3942	0.1543	0.2813	0.0837	0.2745	0.0828	0.1628	0.0182
Self_Gen_ Title_Desc_Guide	0.3530	0.1381	0.2235	0.0274	0.1824	0.0476	0.0829	0.0129
CI	(0.31, 0.39)	(0.11, 0.17)	(0.19, 0.26)	(0.02, 0.04)	(0.15, 0.21)	(0.03, 0.06)	(0.06, 0.10)	(0.01, 0.02)
majority	0.3513	0.1312	0.2275	0.0293	0.2046	0.0356	0.1986	0.0104
inclusion	0.3785	0.1488	0.2688	0.0449	0.2286	0.0643	0.1338	0.0233
GPT_Gen_Title	0.3659	0.1563	0.2522	0.0628	0.2355	0.0603	0.1207	0.0155
CI	(0.33, 0.41)	(0.13, 0.19)	(0.22, 0.29)	(0.05, 0.08)	(0.20, 0.27)	(0.04, 0.08)	(0.10, 0.15)	(0.01, 0.02)
majority	0.3574	0.1617	0.2442	0.0672	0.2374	0.0626	0.1798	0.0052
inclusion	0.3905	0.1562	0.2955	0.0857	0.2893	0.0765	0.1839	0.0301
GPT_Gen_ Title_Desc	0.3835	0.1457	0.2564	0.0669	0.2209	0.0610	0.1080	0.0118
CI	(0.34, 0.43)	(0.12, 0.18)	(0.22, 0.29)	(0.05, 0.08)	(0.19, 0.25)	(0.05, 0.08)	(0.08, 0.13)	(0.01, 0.02)
majority	0.3768	0.1496	0.2413	0.0683	0.2248	0.0540	0.2039	0.0068
inclusion	0.4093	0.1521	0.3005	0.0853	0.2700	0.0821	0.1891	0.0262
GPT_Gen_ Title_Desc_Guide	0.3481	0.1288	0.2549	0.0522	0.2055	0.0602	0.0984	0.0171
CI	(0.31, 0.39)	(0.10, 0.16)	(0.22, 0.29)	(0.04, 0.07)	(0.17, 0.24)	(0.04, 0.08)	(0.08, 0.12)	(0.01, 0.03)
majority	0.3547	0.1348	0.2555	0.0510	0.2333	0.0515	0.1860	0.0077
inclusion	0.3669	0.1387	0.2900	0.0749	0.2684	0.0822	0.1613	0.0332

Table A.13: SemEval — Hybrid classification results on the HI train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.5172	0.2689	0.3651	0.1502	0.3482	0.0853	0.1872	0.0276
CI	(0.48, 0.55)	(0.24, 0.30)	(0.32, 0.41)	(0.12, 0.18)	(0.32, 0.38)	(0.07, 0.10)	(0.16, 0.21)	(0.02, 0.04)
majority	0.5181	0.2803	0.0967	0.0142	0.2926	0.0783	0.1757	0.0164
inclusion	0.5457	0.2670	0.1160	0.0284	0.4159	0.1042	0.2531	0.0475
OrigDesc	0.4917	0.2350	0.3687	0.1472	0.3575	0.0832	0.2123	0.0262
CI	(0.46, 0.53)	(0.21, 0.26)	(0.33, 0.41)	(0.12, 0.17)	(0.33, 0.39)	(0.07, 0.10)	(0.18, 0.24)	(0.02, 0.04)
majority	0.4723	0.2357	0.1067	0.0206	0.3367	0.0783	0.1451	0.0117
inclusion	0.5267	0.2420	0.1235	0.0287	0.4201	0.1052	0.2848	0.0447
Self_Gen_Title	0.4462	0.2145	0.1693	0.0357	0.3114	0.0738	0.1763	0.0234
CI	(0.41, 0.48)	(0.19, 0.24)	(0.14, 0.20)	(0.02, 0.05)	(0.28, 0.34)	(0.06, 0.09)	(0.15, 0.20)	(0.01, 0.03)
majority	0.4363	0.2206	0.1177	0.0185	0.2867	0.0784	0.1284	0.0143
inclusion	0.4947	0.2289	0.3528	0.0951	0.4060	0.0951	0.2672	0.0407
Self_Gen_ Title_Desc	0.4400	0.2041	0.1619	0.0357	0.3456	0.0769	0.1824	0.0209
CI	(0.41, 0.48)	(0.18, 0.23)	(0.13, 0.19)	(0.02, 0.05)	(0.32, 0.37)	(0.06, 0.09)	(0.16, 0.21)	(0.01, 0.03)
majority	0.4352	0.2117	0.1148	0.0179	0.3068	0.0740	0.1273	0.0092
inclusion	0.4871	0.2113	0.3030	0.0925	0.4387	0.0977	0.2731	0.0376
Self_Gen_ Title_Desc_Guide	0.4438	0.1826	0.1662	0.0283	0.2483	0.0521	0.1377	0.0267
CI	(0.41, 0.48)	(0.16, 0.21)	(0.14, 0.20)	(0.02, 0.04)	(0.22, 0.27)	(0.04, 0.07)	(0.12, 0.16)	(0.02, 0.04)
majority	0.4307	0.1881	0.1169	0.0132	0.1761	0.0402	0.0974	0.0163
inclusion	0.4900	0.2018	0.3461	0.0807	0.3579	0.0721	0.2458	0.0448
GPT_Gen_Title	0.4348	0.2002	0.1133	0.0166	0.3384	0.0668	0.1867	0.0233
CI	(0.40, 0.47)	(0.17, 0.23)	(0.09, 0.14)	(0.01, 0.03)	(0.31, 0.37)	(0.05, 0.08)	(0.16, 0.21)	(0.01, 0.03)
majority	0.4151	0.2048	0.1199	0.0192	0.3142	0.0713	0.1314	0.0092
inclusion	0.4895	0.2214	0.1277	0.0223	0.4275	0.0773	0.2611	0.0443
GPT_Gen_ Title_Desc	0.4689	0.2128	0.3991	0.1343	0.3300	0.0679	0.1716	0.0244
CI	(0.43, 0.50)	(0.19, 0.24)	(0.35, 0.44)	(0.11, 0.16)	(0.30, 0.36)	(0.05, 0.08)	(0.15, 0.19)	(0.02, 0.03)
majority	0.4451	0.2127	0.0995	0.0139	0.3016	0.0666	0.1366	0.0171
inclusion	0.5190	0.2247	0.1243	0.0220	0.4204	0.0823	0.2561	0.0414
GPT_Gen_ Title_Desc_Guide	0.4332	0.1870	0.1513	0.0309	0.3262	0.0763	0.1571	0.0301
CI	(0.40, 0.47)	(0.16, 0.21)	(0.12, 0.18)	(0.02, 0.04)	(0.30, 0.35)	(0.06, 0.09)	(0.13, 0.18)	(0.02, 0.04)
majority	0.4184	0.1939	0.1117	0.0148	0.2850	0.0723	0.0976	0.0197
inclusion	0.4760	0.2089	0.1679	0.0372	0.4205	0.0943	0.2469	0.0465

Table A.14: SemEval — Hybrid classification results on the PT train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.5694	0.3615	0.2298	0.0996	0.3515	0.1043	0.2321	0.0351
CI	(0.54, 0.61)	(0.33, 0.39)	(0.20, 0.26)	(0.08, 0.12)	(0.32, 0.38)	(0.09, 0.12)	(0.20, 0.26)	(0.02, 0.05)
majority	0.5806	0.3864	0.2293	0.1010	0.3179	0.1079	0.2362	0.0233
inclusion	0.5590	0.3359	0.2781	0.1256	0.3816	0.1333	0.2595	0.0609
OrigDesc	0.5746	0.3406	0.2867	0.1056	0.3745	0.1024	0.2361	0.0383
CI	(0.54, 0.61)	(0.31, 0.37)	(0.25, 0.32)	(0.09, 0.12)	(0.35, 0.40)	(0.08, 0.12)	(0.21, 0.27)	(0.03, 0.05)
majority	0.5827	0.3545	0.2737	0.0991	0.3687	0.0987	0.2063	0.0218
inclusion	0.5716	0.3202	0.3638	0.1513	0.4001	0.1258	0.2787	0.0660
Self_Gen_Title	0.5071	0.3060	0.3499	0.1218	0.3176	0.0817	0.2108	0.0268
CI	(0.48, 0.54)	(0.28, 0.34)	(0.32, 0.39)	(0.10, 0.14)	(0.29, 0.35)	(0.06, 0.10)	(0.18, 0.24)	(0.02, 0.04)
majority	0.5179	0.3181	0.3808	0.1339	0.2934	0.0694	0.1636	0.0180
inclusion	0.5102	0.2959	0.4137	0.1664	0.3744	0.1190	0.2630	0.0468
Self_Gen_ Title_Desc	0.5310	0.2963	0.2977	0.1180	0.3265	0.0851	0.2057	0.0247
CI	(0.50, 0.57)	(0.27, 0.33)	(0.27, 0.33)	(0.10, 0.14)	(0.30, 0.36)	(0.07, 0.10)	(0.18, 0.24)	(0.01, 0.04)
majority	0.5287	0.3060	0.3091	0.1228	0.3077	0.0777	0.1716	0.0200
inclusion	0.5368	0.2929	0.3927	0.1683	0.3906	0.1127	0.2589	0.0441
Self_Gen_ Title_Desc_Guide	0.5543	0.2916	0.3441	0.0898	0.2681	0.0559	0.1640	0.0279
CI	(0.52, 0.59)	(0.26, 0.32)	(0.31, 0.38)	(0.07, 0.11)	(0.24, 0.30)	(0.04, 0.07)	(0.14, 0.19)	(0.02, 0.04)
majority	0.5613	0.2929	0.3568	0.0917	0.2103	0.0466	0.1316	0.0240
inclusion	0.5518	0.3024	0.4097	0.1208	0.3303	0.0819	0.2662	0.0499
GPT_Gen_Title	0.5244	0.3128	0.3283	0.1063	0.3326	0.0727	0.2187	0.0300
CI	(0.49, 0.56)	(0.28, 0.34)	(0.29, 0.36)	(0.09, 0.12)	(0.30, 0.36)	(0.06, 0.09)	(0.19, 0.25)	(0.02, 0.04)
majority	0.5352	0.3259	0.3576	0.1030	0.3245	0.0680	0.1832	0.0215
inclusion	0.5323	0.3016	0.4005	0.1530	0.3776	0.0946	0.2652	0.0521
GPT_Gen_ Title_Desc	0.5429	0.3255	0.3242	0.1003	0.3221	0.0793	0.2132	0.0248
CI	(0.51, 0.58)	(0.30, 0.36)	(0.29, 0.36)	(0.08, 0.12)	(0.29, 0.35)	(0.06, 0.10)	(0.18, 0.24)	(0.02, 0.04)
majority	0.5466	0.3343	0.3289	0.0972	0.2996	0.0662	0.1616	0.0154
inclusion	0.5413	0.3091	0.3933	0.1424	0.3752	0.1061	0.2672	0.0481
GPT_Gen_ Title_Desc_Guide	0.5335	0.2821	0.3187	0.1059	0.3196	0.0721	0.1858	0.0354
CI	(0.50, 0.57)	(0.25, 0.31)	(0.28, 0.36)	(0.09, 0.13)	(0.29, 0.35)	(0.05, 0.09)	(0.16, 0.21)	(0.02, 0.05)
majority	0.5338	0.2929	0.3111	0.1014	0.2963	0.0547	0.1276	0.0237
inclusion	0.5365	0.2841	0.3972	0.1488	0.3775	0.1039	0.2660	0.0622

Table A.15: SemEval — Hybrid classification results on the BG train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**	**F_1 Coarse**	**F_1 Fine**
Title	0.5388	0.3397	0.1707	0.0871	0.3579	0.1065	0.3027	0.0446
CI	(0.49, 0.58)	(0.30, 0.38)	(0.14, 0.21)	(0.06, 0.11)	(0.32, 0.40)	(0.08, 0.13)	(0.26, 0.34)	(0.03, 0.06)
majority	0.5319	0.3428	0.1654	0.0867	0.3127	0.1081	0.2867	0.0350
inclusion	0.5635	0.3422	0.2238	0.1173	0.3979	0.1271	0.3467	0.0784
OrigDesc	0.5157	0.3048	0.2552	0.1255	0.2983	0.0969	0.3217	0.0443
CI	(0.47, 0.56)	(0.26, 0.35)	(0.22, 0.30)	(0.10, 0.15)	(0.26, 0.33)	(0.07, 0.12)	(0.28, 0.37)	(0.03, 0.06)
majority	0.5182	0.3119	0.2473	0.1191	0.2675	0.0925	0.2398	0.0359
inclusion	0.5276	0.3071	0.3301	0.1644	0.3303	0.1181	0.3908	0.0840
Self_Gen_Title	0.4992	0.2937	0.2562	0.1047	0.3194	0.0620	0.2655	0.0284
CI	(0.45, 0.54)	(0.26, 0.33)	(0.22, 0.29)	(0.08, 0.13)	(0.28, 0.36)	(0.04, 0.08)	(0.22, 0.31)	(0.01, 0.05)
majority	0.4864	0.3041	0.2523	0.1073	0.2773	0.0586	0.1536	0.0126
inclusion	0.5191	0.2985	0.3468	0.1478	0.3677	0.0856	0.3719	0.0550
Self_Gen_ Title_Desc	0.5237	0.2982	0.2550	0.1042	0.3032	0.0679	0.2837	0.0228
CI	(0.48, 0.56)	(0.26, 0.34)	(0.22, 0.29)	(0.08, 0.13)	(0.27, 0.34)	(0.05, 0.09)	(0.24, 0.33)	(0.01, 0.04)
majority	0.5066	0.3178	0.2430	0.0964	0.2482	0.0619	0.1696	0.0155
inclusion	0.5341	0.2890	0.3342	0.1537	0.3480	0.0854	0.3541	0.0427
Self_Gen_ Title_Desc_Guide	0.4932	0.2747	0.2233	0.0550	0.3004	0.0404	0.1806	0.0221
CI	(0.45, 0.54)	(0.24, 0.32)	(0.19, 0.26)	(0.04, 0.08)	(0.26, 0.34)	(0.02, 0.06)	(0.15, 0.22)	(0.01, 0.04)
majority	0.4807	0.2791	0.2263	0.0574	0.2240	0.0277	0.0675	0.0079
inclusion	0.5042	0.2706	0.3162	0.0811	0.3582	0.0649	0.3111	0.0405
GPT_Gen_Title	0.5080	0.3025	0.2399	0.0896	0.3224	0.0689	0.2870	0.0309
CI	(0.46, 0.55)	(0.26, 0.34)	(0.20, 0.28)	(0.07, 0.12)	(0.28, 0.36)	(0.05, 0.09)	(0.24, 0.33)	(0.02, 0.05)
majority	0.5074	0.3178	0.2382	0.0866	0.2611	0.0598	0.1611	0.0081
inclusion	0.5248	0.3031	0.3394	0.1374	0.3879	0.0874	0.3471	0.0596
GPT_Gen_ Title_Desc	0.4998	0.2752	0.2256	0.0958	0.2839	0.0637	0.2597	0.0267
CI	(0.45, 0.55)	(0.24, 0.32)	(0.19, 0.26)	(0.07, 0.12)	(0.25, 0.32)	(0.04, 0.09)	(0.22, 0.30)	(0.01, 0.04)
majority	0.4959	0.2842	0.1968	0.0875	0.2253	0.0597	0.1485	0.0163
inclusion	0.5250	0.2803	0.3271	0.1424	0.3377	0.0846	0.3468	0.0543
GPT_Gen_ Title_Desc_Guide	0.5060	0.2788	0.1969	0.0638	0.2726	0.0564	0.2473	0.0311
CI	(0.46, 0.55)	(0.24, 0.32)	(0.16, 0.23)	(0.04, 0.09)	(0.23, 0.31)	(0.04, 0.08)	(0.21, 0.29)	(0.02, 0.05)
majority	0.5017	0.3035	0.1712	0.0550	0.1813	0.0399	0.1161	0.0187
inclusion	0.5248	0.2708	0.3146	0.1064	0.3577	0.0833	0.3505	0.0618

Table A.16: SemEval — Hybrid classification results on the RU train+dev set: macro F_1 scores and 95% confidence intervals (CI) by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.4296	0.2824	0.4004	0.2640	0.3482	0.2128	0.1792	0.1202
std	0.0227	0.0194	0.0059	0.0045	0.0072	0.0109	0.0168	0.0080
majority	0.4420	0.2860	0.4010	0.2660	0.3720	0.2290	0.1970	0.1480
inclusion	0.4560	0.3000	0.3960	0.2580	0.3510	0.2170	0.2120	0.1330
OrigDesc	0.4884	0.3098	0.4214	0.2862	0.3434	0.2124	0.1666	0.1056
std	0.0161	0.0149	0.0079	0.0081	0.0174	0.0133	0.0234	0.0134
majority	0.4980	0.3080	0.4360	0.3000	0.3600	0.2130	0.1960	0.1420
inclusion	0.5080	0.3250	0.4230	0.2820	0.3740	0.2420	0.2030	0.1180
Self_Gen_Title	0.4362	0.3042	0.3392	0.2208	0.3016	0.1792	0.1424	0.0802
std	0.0231	0.0224	0.0068	0.0054	0.0172	0.0135	0.0142	0.0145
majority	0.4490	0.3230	0.3460	0.2260	0.2950	0.1780	0.1500	0.1090
inclusion	0.4990	0.3500	0.3440	0.2140	0.3570	0.2330	0.1900	0.1080
Self_Gen_ Title_Desc	0.4852	0.3286	0.3592	0.2508	0.3106	0.1764	0.1246	0.0576
std	0.0237	0.0179	0.0150	0.0133	0.0226	0.0188	0.0172	0.0218
majority	0.5160	0.3560	0.3560	0.2510	0.2770	0.1570	0.1740	0.1350
inclusion	0.5040	0.3520	0.3740	0.2500	0.3990	0.2270	0.1740	0.0770
Self_Gen_ Title_Desc_Guide	0.4522	0.3188	0.2810	0.2810	0.2836	0.1890	0.1028	0.0496
std	0.0184	0.0204	0.0055	0.0055	0.0241	0.0132	0.0073	0.0061
majority	0.4550	0.3240	0.2770	0.2770	0.2760	0.1990	0.1780	0.1430
inclusion	0.5080	0.3470	0.2820	0.2810	0.3600	0.2340	0.1610	0.0770
GPT_Gen_Title	0.4442	0.2810	0.3556	0.2350	0.2892	0.1600	0.1274	0.0496
std	0.0202	0.0200	0.0103	0.0083	0.0118	0.0199	0.0208	0.0054
majority	0.4590	0.2810	0.3630	0.2370	0.2780	0.1500	0.1540	0.1130
inclusion	0.4940	0.3330	0.3540	0.2270	0.3520	0.2120	0.1790	0.0780
GPT_Gen_ Title_Desc	0.4684	0.3222	0.3830	0.2676	0.3124	0.1770	0.1178	0.0406
std	0.0248	0.0269	0.0186	0.0186	0.0228	0.0236	0.0107	0.0090
majority	0.4750	0.3250	0.3760	0.2640	0.3280	0.1850	0.1860	0.1280
inclusion	0.5170	0.3630	0.3830	0.2630	0.3550	0.2190	0.1650	0.0690
GPT_Gen_ Title_Desc_Guide	0.4530	0.3236	0.2978	0.2114	0.2526	0.1630	0.1008	0.0340
std	0.0210	0.0135	0.0189	0.0130	0.0146	0.0123	0.0137	0.0066
majority	0.4540	0.3300	0.3070	0.2200	0.2700	0.1780	0.1090	0.0920
inclusion	0.4910	0.3480	0.3230	0.2240	0.3180	0.2020	0.1570	0.0590

Table A.17: SemEval — Three-Step classification results on the EN test set: macro F_1 scores and std by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.5206	0.3216	0.2898	0.2878	0.3632	0.1464	0.1950	0.1172
std	0.0145	0.0265	0.0061	0.0048	0.0108	0.0046	0.0114	0.0176
majority	0.5320	0.3400	0.2950	0.2940	0.3570	0.1470	0.2690	0.2080
inclusion	0.5380	0.3380	0.3070	0.2970	0.3830	0.1770	0.2490	0.1300
OrigDesc	0.4858	0.3018	0.4278	0.3242	0.3398	0.1402	0.1770	0.0800
std	0.0231	0.0145	0.0275	0.0210	0.0106	0.0036	0.0123	0.0138
majority	0.1050	0.0360	0.4220	0.3230	0.3590	0.1550	0.2070	0.1420
inclusion	0.3400	0.1950	0.4730	0.3390	0.3390	0.1510	0.2300	0.1120
Self_Gen_Title	0.4516	0.2602	0.3786	0.2174	0.3014	0.1844	0.1542	0.0616
std	0.0165	0.0179	0.0139	0.0117	0.0338	0.0272	0.0098	0.0130
majority	0.4420	0.2690	0.3720	0.2180	0.3230	0.2120	0.2600	0.2090
inclusion	0.4960	0.2950	0.3890	0.2380	0.3770	0.2140	0.2170	0.0950
Self_Gen_ Title_Desc	0.4682	0.2856	0.3714	0.2046	0.2814	0.1774	0.1878	0.0782
std	0.0085	0.0077	0.0086	0.0091	0.0261	0.0317	0.0322	0.0075
majority	0.4790	0.3070	0.3830	0.2050	0.3230	0.2370	0.2470	0.1720
inclusion	0.5020	0.3010	0.3810	0.2250	0.3610	0.1890	0.2430	0.1120
Self_Gen_ Title_Desc_Guide	0.4536	0.2698	0.3854	0.1814	0.2652	0.0810	0.0890	0.0288
std	0.0248	0.0160	0.0078	0.0091	0.0194	0.0105	0.0179	0.0121
majority	0.4670	0.2940	0.3990	0.1860	0.3160	0.1450	0.1710	0.1550
inclusion	0.4850	0.2920	0.4060	0.2070	0.3140	0.1140	0.1820	0.0650
GPT_Gen_Title	0.4690	0.2654	0.3422	0.1804	0.2952	0.1818	0.1582	0.0654
std	0.0132	0.0138	0.0105	0.0089	0.0257	0.0261	0.0185	0.0121
majority	0.4690	0.2850	0.3250	0.1600	0.3020	0.1960	0.2070	0.1620
inclusion	0.5020	0.2830	0.3590	0.1960	0.3870	0.2260	0.2310	0.1060
GPT_Gen_ Title_Desc	0.4574	0.2670	0.3716	0.2182	0.2834	0.1776	0.1758	0.0826
std	0.0096	0.0131	0.0158	0.0144	0.0378	0.0296	0.0185	0.0115
majority	0.4740	0.2940	0.3940	0.2270	0.3330	0.2340	0.1950	0.1590
inclusion	0.4910	0.2760	0.3870	0.2250	0.3650	0.2090	0.2390	0.1190
GPT_Gen_ Title_Desc_Guide	0.4500	0.2692	0.3804	0.1926	0.2804	0.1360	0.1236	0.0440
std	0.0198	0.0152	0.0138	0.0080	0.0299	0.0230	0.0133	0.0105
majority	0.4520	0.2810	0.3840	0.1820	0.2680	0.1560	0.2550	0.2160
inclusion	0.4650	0.2850	0.3830	0.2140	0.3610	0.1800	0.1850	0.0780

Table A.18: SemEval — Hybrid classification results on the EN test set: macro F_1 scores and std by model and prompting strategy.

	Calme		Gemma		Exaone		Granite	
	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine	F_1 Coarse	F_1 Fine
Title	0.4038	0.2144	0.2856	0.2842	0.2604	0.1682	0.1712	0.1196
std	0.0132	0.0115	0.0050	0.0050	0.0186	0.0152	0.0410	0.0334
majority	0.4310	0.2300	0.2870	0.2870	0.2340	0.1860	0.2210	0.1910
inclusion	0.4640	0.2620	0.2930	0.2860	0.3430	0.1880	0.2320	0.1370
OrigDesc	0.3806	0.2112	0.2916	0.2844	0.2748	0.1872	0.1846	0.1186
std	0.0234	0.0174	0.0117	0.0125	0.0216	0.0173	0.0375	0.0372
majority	0.3820	0.2250	0.2770	0.2770	0.3440	0.3010	0.2770	0.2280
inclusion	0.4420	0.2480	0.3340	0.3070	0.3290	0.1850	0.2240	0.1210
Self_Gen_Title	0.3578	0.1880	0.2704	0.2434	0.1898	0.1254	0.1968	0.1612
std	0.0131	0.0078	0.0343	0.0314	0.0271	0.0172	0.0356	0.0338
majority	0.3390	0.1800	0.2750	0.2620	0.1570	0.1210	0.2970	0.2870
inclusion	0.4080	0.2350	0.3360	0.2610	0.2400	0.1340	0.2280	0.1430
Self_Gen_ Title_Desc	×	×	0.2542	0.2420	0.1898	0.1188	0.1724	0.1396
std	×	×	0.0166	0.0185	0.0284	0.0225	0.0321	0.0315
majority	×	×	0.2570	0.2570	0.2330	0.2050	0.2710	0.2570
inclusion	×	×	0.2900	0.2340	0.2410	0.1180	0.2160	0.1260
Self_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.1444	0.1102
std	×	×	×	×	×	×	0.0248	0.0266
majority	×	×	×	×	×	×	0.2110	0.2080
inclusion	×	×	×	×	×	×	0.1980	0.1170
GPT_Gen_Title	0.3814	0.2058	0.2782	0.2544	0.1596	0.0998	0.1936	0.1488
std	0.0196	0.0270	0.0168	0.0114	0.0181	0.0203	0.0346	0.0306
majority	0.3680	0.2190	0.2770	0.2690	0.1450	0.1100	0.2720	0.2570
inclusion	0.4290	0.2440	0.3090	0.2340	0.2120	0.1120	0.2420	0.1430
GPT_Gen_ Title_Desc	0.3720	0.2172	0.2652	0.2544	0.1788	0.0958	0.1888	0.1394
std	0.0181	0.0136	0.0128	0.0180	0.0260	0.0249	0.0298	0.0200
majority	0.4040	0.2450	0.2760	0.2690	0.1650	0.1340	0.2800	0.2480
inclusion	0.4270	0.2460	0.3180	0.2720	0.2270	0.0930	0.2170	0.1250
GPT_Gen_ Title_Desc_Guide	×	×	×	×	×	×	0.2008	0.1686
std	×	×	×	×	×	×	0.0343	0.0299
majority	×	×	×	×	×	×	0.2920	0.2870
inclusion	×	×	×	×	×	×	0.2350	0.1480

Table A.19: SemEval — All-in-One classification results on the EN test set: macro F_1 scores and std by model and prompting strategy.